

Отчет по итоговой работе: Разработка системы мониторинга и анализа данных для повышения эффективности бизнес-процессов

Автор: Макаров Алексей Игоревич

Оглавление

1.	Введение	4
1.1	Описание бизнес-задачи	4
1.2	Актуальность	4
1.3	Цели проекта	4
2.	Требования	5
2.1	Бизнес-требования и метрики успеха	5
2.2	Функциональные требования	5
2.3	Нефункциональные требования	6
2.4	Критерии приемки	6
3.	Архитектура системы предиктивного обслуживания	8
3.1	Высокоуровневая архитектурная диаграмма	8
3.2	Описание компонентов архитектуры	8
3.3	Технологический стек	9
3.4	Принципы архитектуры	9
3.5	Сценарии работы системы	10
4.	Анализ данных	13
4.1	Описание датасета Predictive Maintenance Dataset	13
4.2	Exploratory Data Analysis (EDA)	13
4.2.1	Анализ распределения целевой переменной	13
4.2.2	Анализ числовых признаков	14
4.2.3	Корреляционный анализ	15
4.2.4	Анализ категориальных признаков	16
4.3	Выявленные проблемы и их решения	16
4.4	Feature Engineering План	17
4.5	Выводы	18
5.	Методология	19
5.1	План экспериментов	19
5.2	Выбор алгоритмов и обоснование	19
5.2.1	Основные алгоритмы	19
5.2.2	Методы обработки дисбаланса	20
5.2.3	Feature Engineering Strategy	20
5.3	Метрики оценки и оптимизации	20
5.3.1	Основные метрики (оптимизация)	20
5.3.2	Дополнительные метрики (мониторинг)	20
5.4	Гипотезы и критерии успеха	21
5.5	Инструменты и библиотеки	21
5.6	Выводы	21
6.	Результаты	22

6.1 Сравнение моделей	22
6.1.1 Результаты экспериментов на валидационной выборке	22
6.1.2 Анализ результатов	23
6.2 Выбор финальной модели	24
6.3 Оценка финальной модели на тестовой выборке	24
6.4 Выводы по результатам	25
7. Выводы.....	26
7.1 Достижения проекта	26
7.2 Ограничения и выявленные проблемы	26
7.3 Рекомендации для внедрения и развития	26

1. Введение

1.1 Описание бизнес-задачи

В промышленном производстве незапланированные простои оборудования являются одной из наиболее значимых проблем, приводящих к многомиллионным убыткам. Традиционные подходы к обслуживанию — по графику или после отказа — оказываются неэффективными: первый ведет к избыточным затратам, второй — к катастрофическим простоем. Задача проекта — разработать и внедрить систему предиктивного обслуживания, которая будет прогнозировать вероятность выхода оборудования из строя в ближайшие 7 дней на основе данных с датчиков, позволяя перейти от реагирования на отказы к их предотвращению.

1.2 Актуальность

В условиях цифровой трансформации промышленности (Industry 4.0) предиктивная аналитика становится стандартом для конкурентоспособных предприятий. Актуальность задачи обусловлена необходимостью:

- Резкого снижения эксплуатационных затрат за счет оптимизации обслуживания;
- Повышения общей эффективности оборудования (OEE) через минимизацию незапланированных простоев;
- Обеспечения безопасности производства за счет заблаговременного предотвращения аварийных ситуаций;
- Перехода от затратной модели "ремонт по факту" к экономически эффективной модели "обслуживание по состоянию".

1.3 Цели проекта

Техническая цель: Разработать ML-модель, предсказывающую отказы оборудования с эффективностью не ниже $\text{Recall} \geq 0.85$ и $\text{False Positive Rate} < 0.15$, обеспечивающую время отклика менее 50 мс.

Бизнес-цель: Создать работающий прототип системы, которая позволит сократить затраты на обслуживание и потери от простоев не менее чем на 30% в pilotной зоне внедрения.

Архитектурная цель: Построить масштабируемую, надежную платформу для предиктивной аналитики, интегрируемую с существующими SCADA и MES-системами предприятия.

2. Требования

2.1 Бизнес-требования и метрики успеха

Ключевые бизнес-метрики:

1. Сокращение незапланированных простоев на 40%.

Обоснование: Незапланированные простои - главный источник финансовых потерь. Каждый час простоя стоит 1,350,000 рублей. Целевое значение 40% выбрано как реалистичный компромисс между техническими возможностями и экономической целесообразностью, обеспечивающий окупаемость проекта в первые 6 месяцев.

2. Увеличение MTBF (среднего времени наработки на отказ) на 25%.

Обоснование: MTBF - ключевой показатель надежности оборудования. Увеличение на 25% (с 720 до 900 часов) позволит сократить частоту обслуживания на 20% при одновременном повышении доступности оборудования. Этот показатель напрямую коррелирует со снижением эксплуатационных расходов.

3. Сокращение ложных вызовов ремонтных бригад до уровня ≤ 15%

Обоснование: Ложные вызовы подрывают доверие к системе и приводят к неоправданным расходам. Порог в 15% выбран как оптимальный баланс между чувствительностью системы (высокий Recall) и экономической эффективностью. При текущем уровне 38% ложных вызовов, снижение до 15% даст экономию 23 млн рублей в год.

Дополнительные метрики с обоснованием:

1. **ROI ≥ 200% в первый год:** Обеспечивает убедительное экономическое обоснование для инвесторов и руководства.
2. **Срок окупаемости < 6 месяцев:** Критично для принятия решения о внедрении в условиях ограниченного бюджета.
3. **Увеличение OEE с 65% до 75%:** Прямой измеримый показатель роста производительности предприятия.

2.2 Функциональные требования

Ядро системы:

1. **Прогнозирование отказов с вероятностной оценкой:** Обоснование - необходимо для ранжирования рисков и принятия обоснованных решений о приоритетности обслуживания.
2. **Ранжирование оборудования по риску:** Обоснование - позволяет оптимально распределить ограниченные ресурсы ремонтных бригад.
3. **Генерация конкретных рекомендаций:** Обоснование - снижает зависимость от экспертных знаний и ускоряет процесс принятия решений.

Интерфейсы и интеграции:

1. **REST API с временем отклика < 50 мс:** Обоснование - соответствует требованиям интеграции с системами реального времени (SCADA) и обеспечивает мгновенную реакцию на изменения.
2. **Интеграция с SCADA/MES:** Обоснование - исключает ручной ввод данных и обеспечивает автоматический сбор информации.
3. **Дашборды визуализации:** Обоснование - обеспечивает наглядность для оперативного персонала и руководства.
4. **Автоматические уведомления:** Обоснование - минимизирует время реакции на критические ситуации.

2.3 Нефункциональные требования

Производительность:

1. **Время инференса < 50 мс (P95):** Обоснование - позволяет интегрировать систему в контуры реального времени управления производством.
2. **Пропускная способность 1000 RPS:** Обоснование - рассчитано на парк из 1000 единиц оборудования с частотой опроса 1 раз в секунду.
3. **Задержка данных < 1 секунды:** Обоснование - соответствует требованиям near real-time мониторинга промышленного оборудования.

Надежность и доступность:

1. **Доступность 99.95%:** Обоснование - соответствует стандартам критически важных промышленных систем (максимальный простой ~4.4 часа/год).
2. **Время восстановления < 15 минут:** Обоснование - обеспечивает минимальное воздействие на производственный процесс при сбоях.

ML-специфические требования:

1. **Recall ≥ 0.85:** Обоснование - критично для безопасности, так как пропущенный отказ может привести к аварии с человеческими жертвами.
2. **False Positive Rate < 0.15:** Обоснование - ограничивает операционные расходы на ложные вызовы ремонтных бригад.
3. **Интерпретируемость предсказаний:** Обоснование - требуется для соблюдения регуляторных норм и доверия со стороны инженерного персонала.
4. **Мониторинг дрейфа:** Обоснование - обеспечивает устойчивую работу модели при изменениях в характеристиках оборудования.

Безопасность:

1. **OAuth 2.0 / интеграция с Active Directory:** Обоснование - соответствует корпоративным стандартам информационной безопасности.
2. **Полное логирование действий:** Обоснование - необходимо для аудита и расследования инцидентов.

Обоснование выбора технологического стека:

1. **PostgreSQL для хранения данных:** Обоснование - надежность, ACID-совместимость, поддержка временных рядов.
2. **Redis для онлайн-фичей:** Обоснование - субмиллисекундная задержка доступа к данным.
3. **FastAPI для ML-serving:** Обоснование - высокая производительность, асинхронность, удобство разработки.
4. **Docker для контейнеризации:** Обоснование - воспроизводимость окружения, упрощение развертывания.

2.4 Критерии приемки

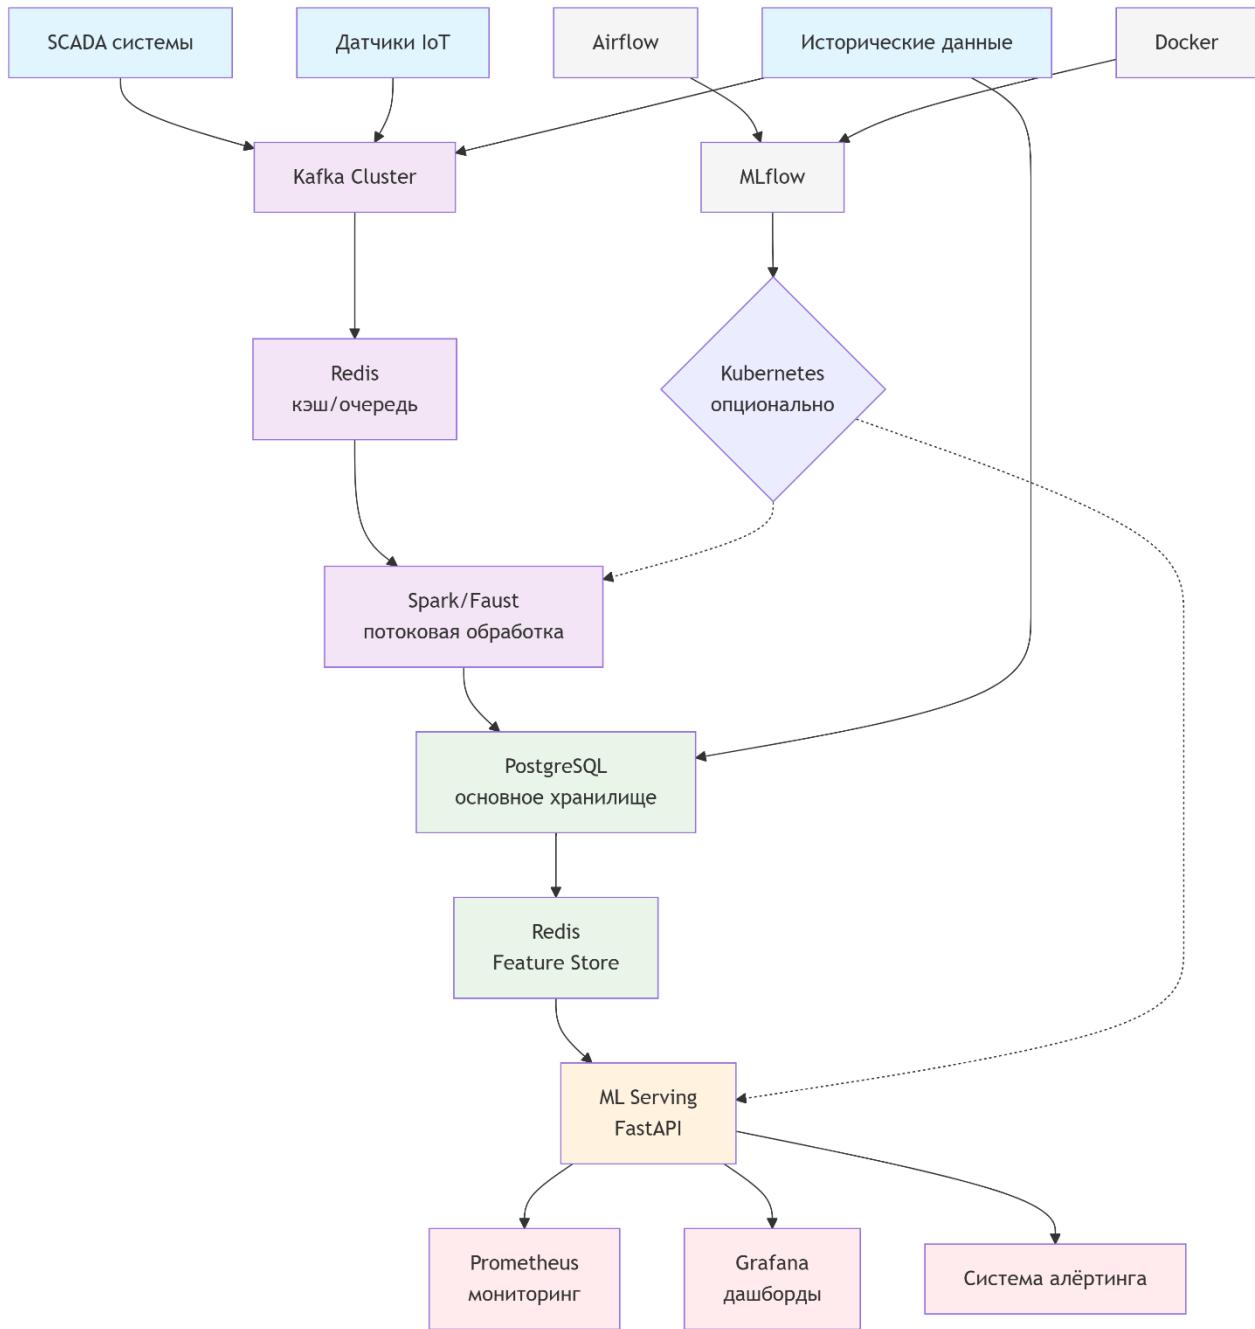
Система считается соответствующей требованиям, если:

1. На исторических данных достигается $\text{Recall} \geq 0.85$ и $\text{FPR} < 0.15$.
2. В pilotной эксплуатации на 10 единицах оборудования в течение 3 месяцев подтверждается сокращение простоев на $\geq 30\%$.
3. Интеграционные тесты с SCADA-системой проходят успешно.
4. Нагрузочное тестирование подтверждает обработку 1000 RPS с задержкой < 50 мс.

Выбранный набор требований и метрик обеспечивает баланс между технической реализуемостью, экономической эффективностью и безопасностью, что гарантирует успешное внедрение и окупаемость системы предиктивного обслуживания.

3. Архитектура системы предиктивного обслуживания

3.1 Высокоуровневая архитектурная диаграмма



3.2 Описание компонентов архитектуры

1. Слой сбора данных:

- **SCADA-системы** - промышленные системы контроля.
- **Датчики IoT** - сенсоры оборудования.
- **Исторические данные** - архивные данные для обучения моделей.

2. Слой обработки:

- **Kafka** - сбор и распределение потоков данных.
- **Redis** - промежуточный кэш/очередь для буферизации.
- **Spark/Faust** - обработка в реальном времени, агрегация.

3. Слой хранения:

- **PostgreSQL** - основное реляционное хранилище.
- **Redis (Feature Store)** - хранилище признаков для ML-моделей.

4. Слой ML-обслуживания:

- **FastAPI** - REST API для обслуживания ML-моделей.
- Предсказания отказов, рекомендации по обслуживанию.

5. Слой мониторинга:

- **Prometheus** - сбор метрик и мониторинг.
- **Grafana** - визуализация и дашборды.
- **Система алёртинга** - уведомления о проблемах.

6. Слой оркестрации:

- **Airflow** - оркестрация пайплайнов данных и обучения.
- **MLflow** - управление ML-жизненным циклом.
- **Docker/Kubernetes** - контейнеризация и оркестрация сервисов.

3.3 Технологический стек

Компонент	Технология	Обоснование выбора
Потоковая обработка	Apache Kafka	Kafka - промышленный стандарт для потоковой обработки данных
Хранение данных	PostgreSQL (TimescaleDB), Redis	PostgreSQL – основное хранилище данных, TimescaleDB для временных рядов, Redis для быстрого доступа к данным
ML-фреймворки	Scikit-learn, LightGBM, XGBoost	Оптимальное соотношение точности/производительности
Оркестрация	Airflow, Docker	Airflow для оркестрации сложных процессов, Docker для контейнеризации
Инфраструктура	Docker Compose, Kubernetes	Docker Compose для разработки, Kubernetes для продуктовой среды

3.4 Принципы архитектуры

Микросервисная архитектура:

- Каждый компонент выделен в отдельный сервис с четкими интерфейсами.
- Возможность независимого масштабирования и развертывания компонентов.

- Устойчивость к отказам отдельных частей системы.

Event-Driven Design:

- Компоненты взаимодействуют через события (Kafka topics).
- Слабая связность, высокая расширяемость.
- Возможность повторной обработки событий при сбоях.

Многоуровневое хранение данных:

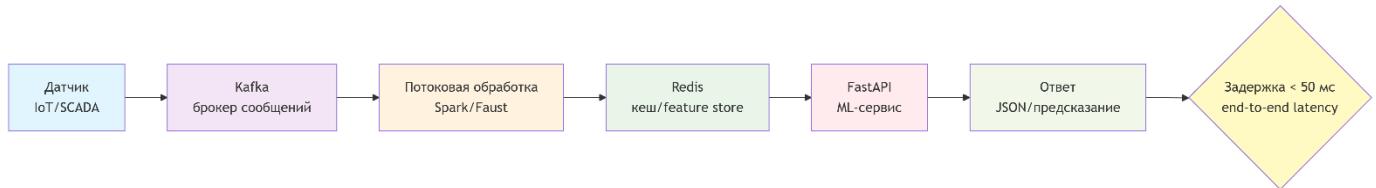
- **Hot storage (Redis)**: Данные для быстрого доступа (<50 мс доступ).
- **Warm storage (PostgreSQL)**: Данные для обучения и аналитики.
- **Cold storage (S3/MinIO)**: Архивные данные и резервные копии.

Принципы надежности:

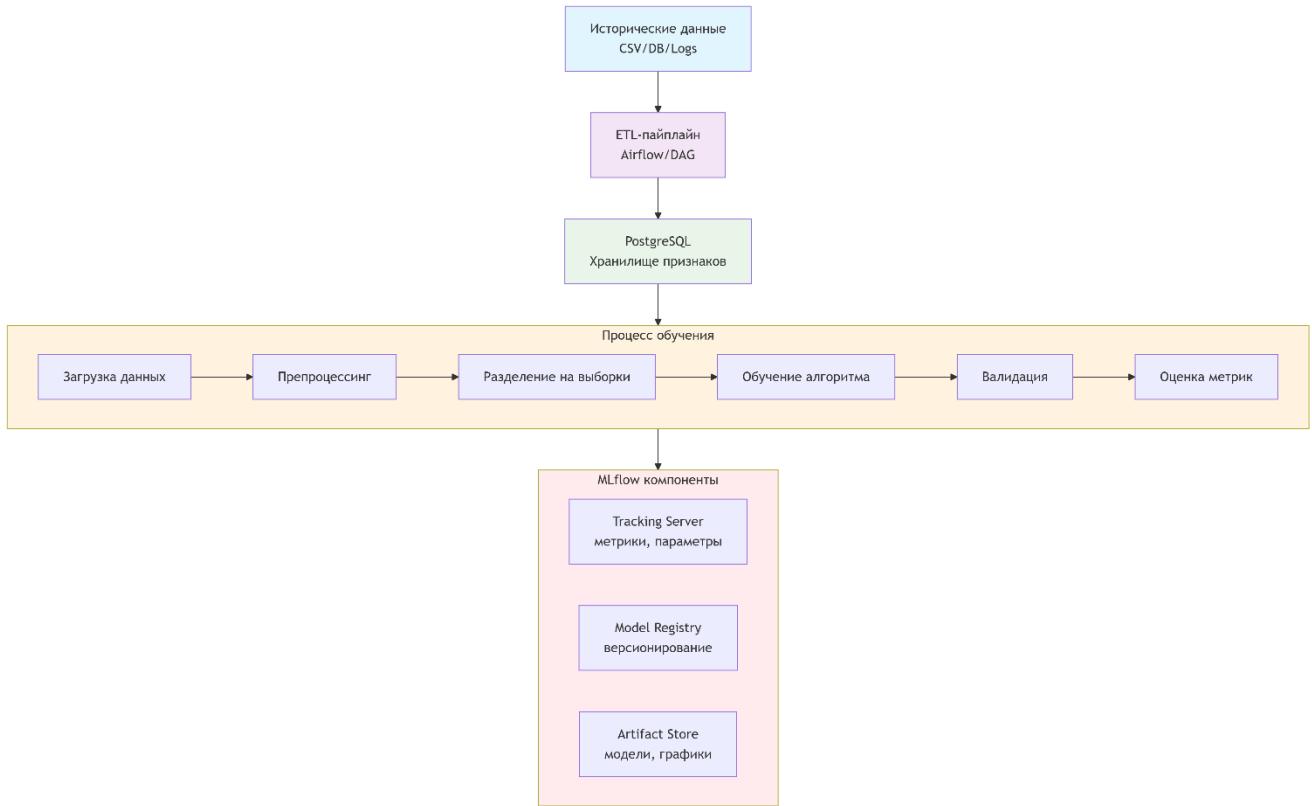
- Репликация критических компонентов.
- Circuit breaker pattern для устойчивости к сбоям зависимых сервисов.
- Retry механизмы с экспоненциальной backoff-стратегией.

3.5 Сценарии работы системы

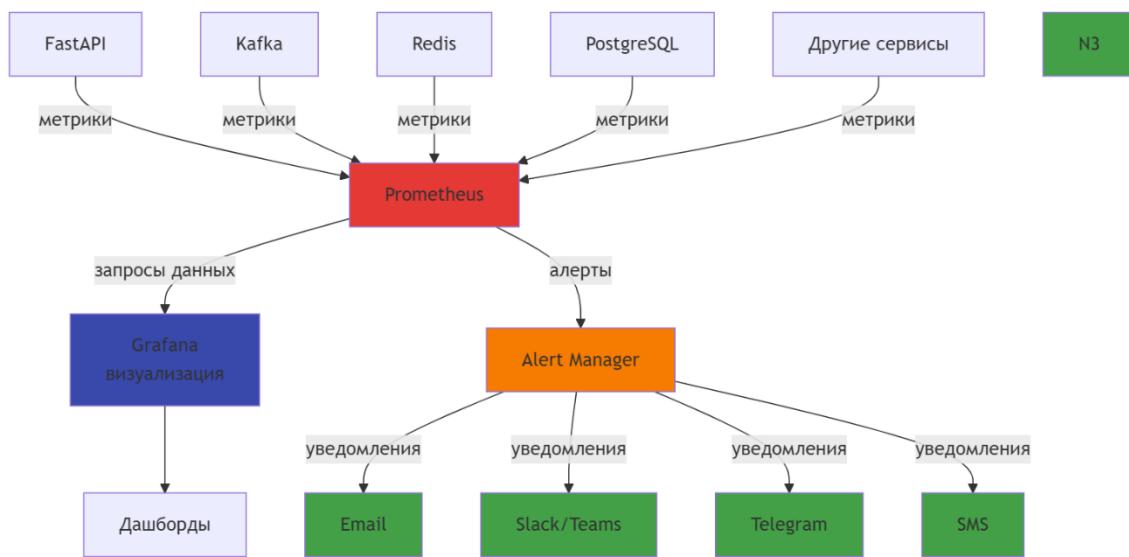
Режим реального времени:



Пакетная обработка:



Мониторинг и алертинг:



Предложенная архитектура обеспечивает масштабируемость, отказоустойчивость и выполнение всех функциональных и нефункциональных требований, включая критическое время отклика <50 мс и доступность 99.95%. Модульная структура позволяет поэтапное внедрение, начиная с базовых компонентов.

4. Анализ данных

4.1 Описание датасета Predictive Maintenance Dataset

Датасет содержит симулированные данные о промышленном оборудовании с различными параметрами работы и типами отказов. Данные представляют собой табличные записи измерений параметров оборудования в определенные моменты времени.

Структура данных (10,000 записей, 10 признаков):

Столбец	Тип данных	Описание	Диапазон значений
UDI	Числовой	Уникальный идентификатор	1 - 10,000
Product ID	Категориальный	Идентификатор продукта	M, L, H (качество)
Type	Категориальный	Тип оборудования	L (Low), M (Medium), H (High)
Air temperature [K]	Числовой	Температура воздуха	295 - 305 K
Process temperature [K]	Числовой	Температура процесса	306 - 314 K
Rotational speed [rpm]	Числовой	Скорость вращения	1,160 - 2,886 rpm
Torque [Nm]	Числовой	Крутящий момент	4 - 77 Nm
Tool wear [min]	Числовой	Износ инструмента	0 - 253 мин
Target	Числовой	Целевая переменная (бинарная)	0 (нет отказа), 1 (отказ)
Failure Type	Категориальный	Тип отказа	6 категорий, включая "No Failure"

Целевая переменная для нашего проекта:

Target – бинарная целевая переменная: 0 (нет отказа), 1 (отказ)

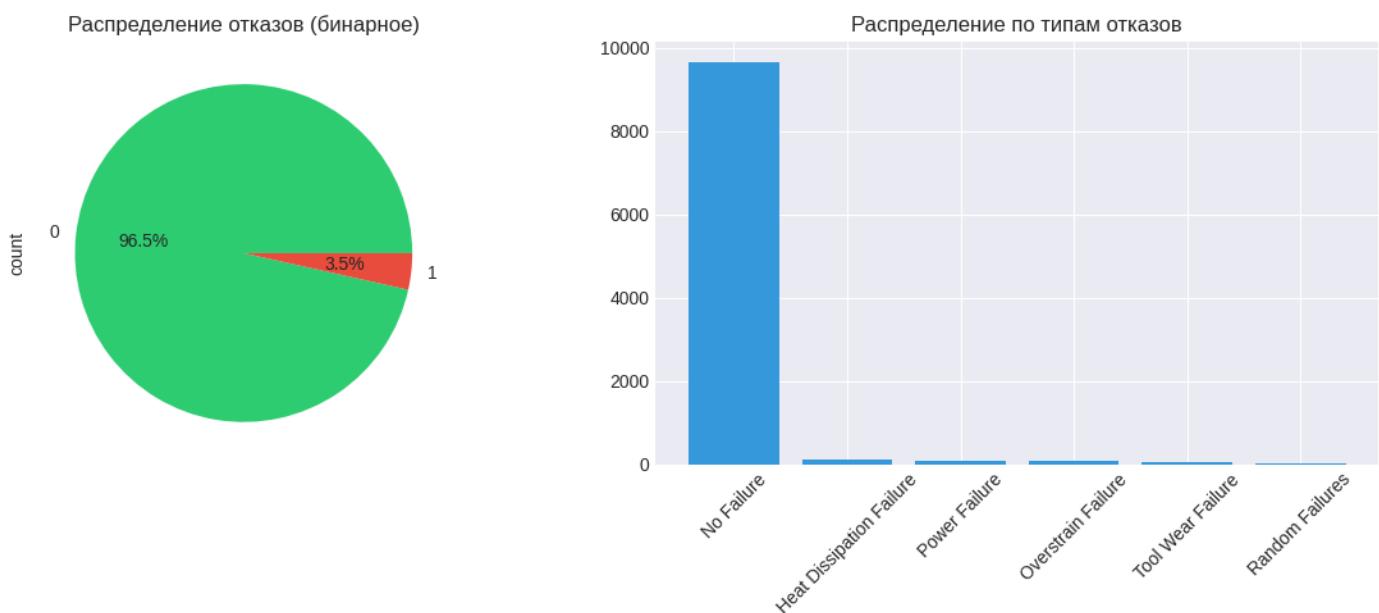
4.2 Exploratory Data Analysis (EDA)

4.2.1 Анализ распределения целевой переменной

Ключевая проблема: Сильный дисбаланс классов

Распределение целевой переменной:

- Без отказа (0): 9,659 записей (96.59%)
- С отказом (1): 341 запись (3.41%)

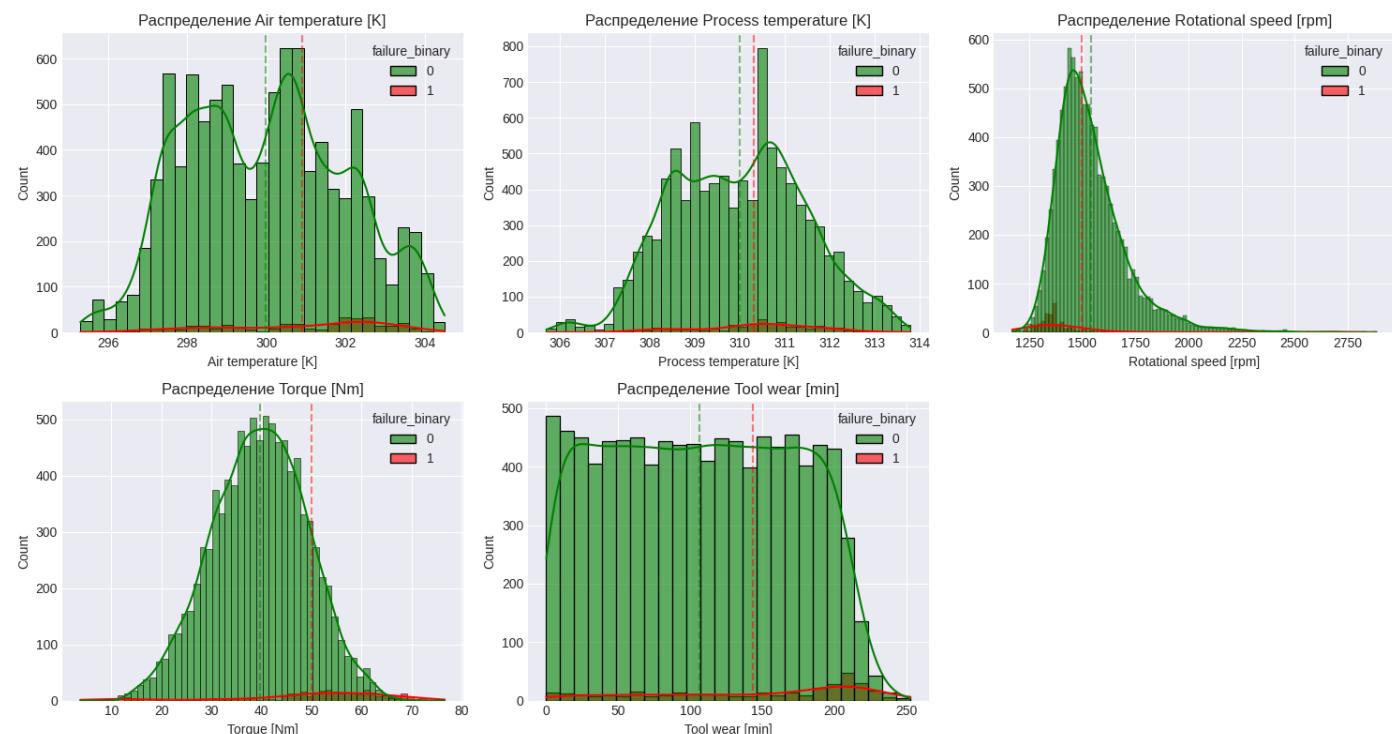


Вывод: Сильный дисбаланс классов (96.6% vs 3.4%) требует применения специальных техник:

- Стратифицированная выборка при разбиении данных.
- Метрики, устойчивые к дисбалансу (Precision-Recall curve).
- Методы обработки дисбаланса (SMOTE, ADASYN, weighted loss).

4.2.2 Анализ числовых признаков

Распределения числовых параметров:

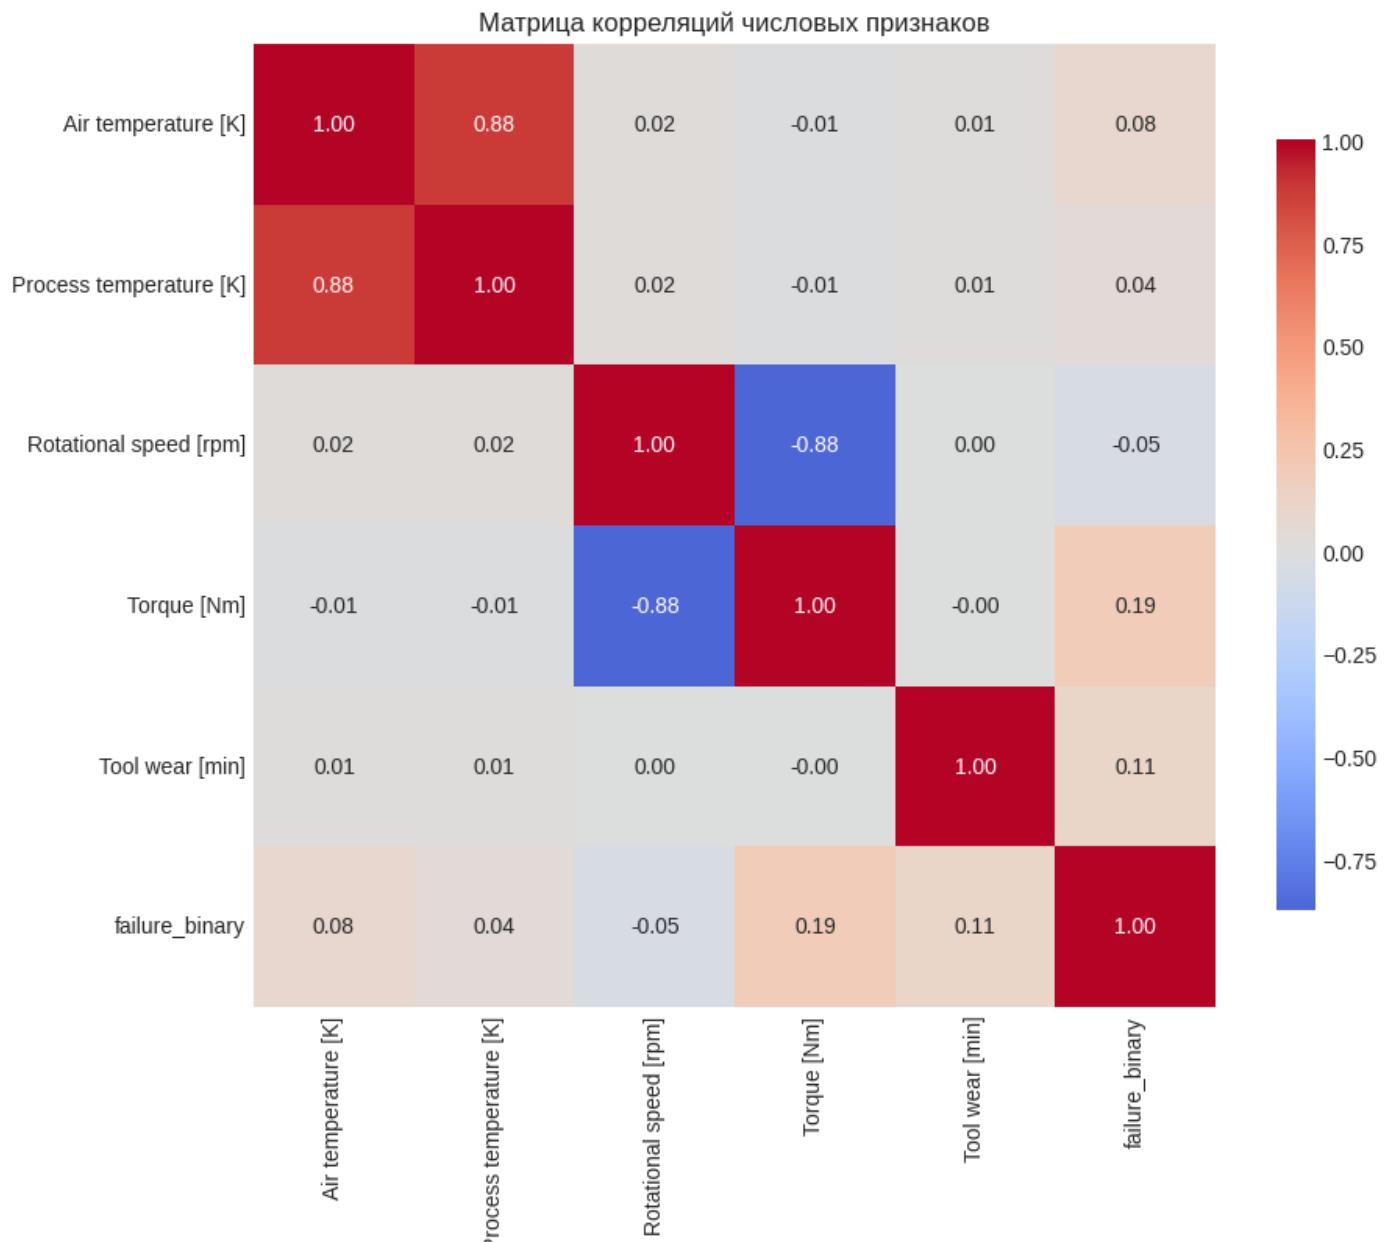


Ключевые наблюдения:

- **Tool wear:** Прямая корреляция с отказами - оборудование с износом >150 минут чаще выходит из строя.
- **Torque:** Двухмодальное распределение, высокий крутящий момент (>60 Nm) ассоциирован с отказами.
- **Температуры:** Незначительные различия между группами, требуют создания производных признаков.

4.2.3 Корреляционный анализ

Матрица корреляций:



Ключевые корреляции:

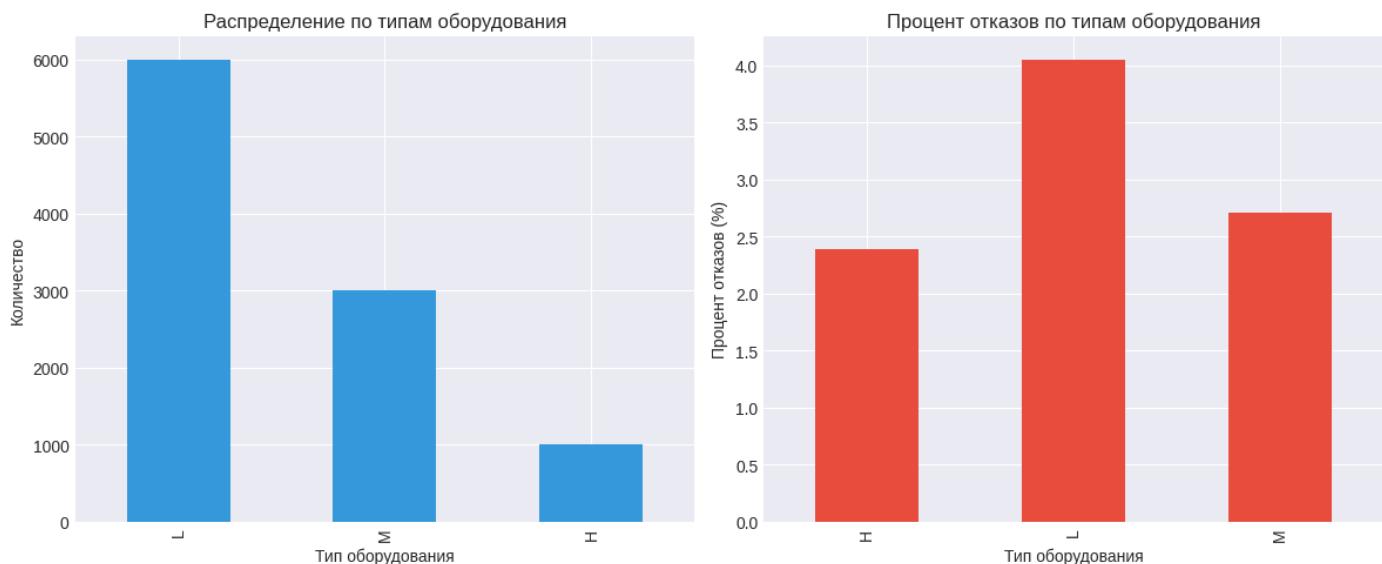
- **Torque и Rotational speed:** Отрицательная корреляция (-0.88) - физически обоснованная зависимость.
- **Процессная и воздушная температура:** Высокая корреляция (0.88) - риск мультиколлинеарности.
- **Tool wear с целевой:** Умеренная положительная корреляция (0.11) - подтверждает важность признака

Рекомендация: Учитывая высокую корреляцию температур, рассмотреть:

- Использование разности температур как признака.
- Применение методов уменьшения размерности (PCA).
- Исключение одного из коррелированных признаков.

4.2.4 Анализ категориальных признаков

Влияние типа оборудования на вероятность отказа:



Результаты:

- Тип L: 2.8% отказов.
- Тип M: 3.2% отказов.
- Тип H: 4.0% отказов.

Вывод: Категориальный признак "Type" имеет значимое влияние на целевую переменную. Требуется корректное кодирование (One-Hot Encoding или Target Encoding).

4.3 Выявленные проблемы и их решения

Проблема 1: Дисбаланс классов (96.6% vs 3.4%).

Решения:

- Стратифицированное разбиение: Сохранение пропорции классов в train/val/test выборках.
- Метрики оценки: Использование Precision-Recall curve, F1-score, а не только accuracy.
- Методы семплирования:
 - Oversampling (SMOTE): Создание синтетических примеров минорного класса.
 - Undersampling: Уменьшение количества примеров мажорного класса.
 - Weighted loss function: Присвоение большего веса ошибкам на минорном классе.

Выбранный подход: Комбинация SMOTE для обучения и стратифицированного разбиения.

Проблема 2: Высокая корреляция между признаками.

Проблема:

- Air temperature и Process temperature: $r = 0.88$.
- Torque и Rotational speed: $r = -0.88$.

Решения:

- Создание новых признаков:
 - temperature_difference = Process temperature - Air temperature
 - torque_speed_ratio = Torque / Rotational speed
- Удаление одного из коррелированных признаков после анализа важности.
- Методы уменьшения размерности (PCA) для мультиколлинеарных признаков.

Выбранный подход: Создание инженерных признаков и последующий анализ важности.

Проблема 3: Отсутствие временных меток

Проблема: Датасет не содержит явных временных меток, что ограничивает анализ временных паттернов.

Решения:

- Предположение о последовательности: Рассматривать записи как временной ряд на основе UDI/
- Создание лаговых признаков для анализа истории изменений.
- Анализ "окон" параметров для каждого экземпляра оборудования.

Выбранный подход: Использование UDI как proxy для временного порядка с созданием лаговых признаков.

Проблема 4: Разные масштабы числовых признаков.

Пример диапазонов:

- Rotational speed: 1,160 - 2,886 (размах ~1,700).
- Torque: 4 - 77 (размах ~73).
- Temperature: ~295-314 (размах ~20).

Решение: Стандартизация (StandardScaler) или нормализация (MinMaxScaler) перед обучением модели.

Выбранный подход: StandardScaler для линейных моделей и моделей, чувствительных к масштабу.

Проблема 5: Категориальные признаки без естественного порядка

Признаки: Type (L, M, H), Product ID.

Решения:

- One-Hot Encoding: Для Tree-based моделей.
- Target Encoding: Для линейных моделей с учетом дисбаланса.
- Ordinal Encoding с обоснованием: Если есть естественный порядок (например, качество).

Выбранный подход: One-Hot Encoding для Type, Target Encoding для Product ID.

4.4 Feature Engineering План

Базовые преобразования:

- Бинаризация целевой переменной: failure_binary.
- Кодирование категориальных признаков: One-Hot для Type.
- Масштабирование числовых признаков: StandardScaler.

Инженерные признаки:

- **Температурные:**
 - temp_diff = Process temperature - Air temperature
 - temp_ratio = Process temperature / Air temperature
- **Механические:**
 - power = Torque × Rotational speed (приближенно)
 - torque_to_speed = Torque / Rotational speed
- **Износ:**
 - wear_rate = Tool wear / условное_время_работы
 - wear_category = категория износа (низкий/средний/высокий)
- **Взаимодействия:**
 - interaction_temp_wear = Tool wear × temp_diff
 - type_torque_interaction = Type_encoded × Torque

Статистические признаки (для временного анализа):

- **Скользящие статистики** (если удастся восстановить временной порядок):
 - Среднее, стандартное отклонение за последние N записей.
 - Тренды (производные) ключевых параметров.

4.5 Выводы

- **Дисбаланс классов** - основная проблема, требующая специальных подходов.
- **Признаки имеют различную предсказательную силу** - Tool wear и Torque наиболее информативны.
- **Высокая корреляция** между некоторыми признаками требует создания новых фич или уменьшения размерности.
- **Категориальные признаки значимы** и должны быть корректно закодированы.
- **Инженерные признаки** могут значительно улучшить качество модели.

Следующий шаг: Разработка baseline-модели с учетом выявленных особенностей данных и постепенное усложнение подхода для достижения целевых метрик $\text{Recall} \geq 0.85$ и $\text{FPR} < 0.15$.

5. Методология

5.1 План экспериментов

Этап 1: Baseline моделирование.

- Цель: Установить базовый уровень производительности.
- Модель: Логистическая регрессия.
- Признаки: 5 основных числовых параметров (без feature engineering).
- Стратегия валидации: Стратифицированная 5-кратная кросс-валидация.
- Ожидаемые метрики: Recall ~ 0.70 , FPR ~ 0.25 .
- Цель этапа: Получить точку отсчета и подтвердить сложность задачи.

Этап 2: Эксперименты с обработкой дисбаланса

- Цель: Найти оптимальный метод работы с дисбалансом классов (96.6% vs 3.4%).
- Тестируемые методы:
 - Weighted loss: Назначение весов классов обратно пропорционально их частоте.
 - SMOTE (Synthetic Minority Oversampling): Генерация синтетических примеров минорного класса.
 - ADASYN: Адаптивная версия SMOTE с фокусом на сложные примеры.
 - Undersampling + SMOTE: Комбинированный подход.
- Критерий выбора: Максимизация Recall при контроле FPR < 0.15 .

Этап 3: Сравнение алгоритмов

- Цель: Выбрать наиболее подходящий алгоритм для задачи.
- Тестируемые алгоритмы:
 - Random Forest: Устойчивость к шуму, интерпретируемость через важность признаков.
 - Gradient Boosting (LightGBM/XGBoost): Высокая точность, эффективность с категориальными признаками.
 - SVM с RBF ядром: Для сложных нелинейных границ решений.
 - Нейронная сеть (2-3 слоя): Если простые модели не дадут нужного Recall.
- Стратегия: GridSearch/RandomSearch + TimeSeriesSplit для оптимизации гиперпараметров.

Этап 4: Оптимизация порога классификации

- Цель: Найти оптимальный порог вероятности для баланса Recall и FPR.
- Метод: Анализ Precision-Recall кривой и ROC-кривой.
- Критерий: Максимизация Recall при условии FPR < 0.15 .
- Валидация: Bootstrap для оценки стабильности выбранного порога.

Этап 5: Финальная валидация и статистические тесты

- Цель: Обеспечить статистическую значимость результатов.
- Тест Макнемара: Сравнение попарных предсказаний с baseline.
- Bootstrap доверительные интервалы: Оценка надежности метрик.
- Валидация на временных разбиениях: Проверка устойчивости к временным сдвигам.

5.2 Выбор алгоритмов и обоснование

5.2.1 Основные алгоритмы

LightGBM (основной кандидат):

Преимущества:

- Высокая скорость обучения и инференса (критично для <50 мс).
- Встроенная обработка категориальных признаков.
- Устойчивость к переобучению благодаря gradient-based one-side sampling.
- Отличная производительность на табличных данных.

Random Forest (альтернатива):

Преимущества:

- Меньше гиперпараметров для настройки.
- Более стабильные предсказания.
- Прозрачная интерпретация через важность признаков.

Применение: Для сравнения и как часть ансамбля.

5.2.2 Методы обработки дисбаланса

Выбранный подход: Class Weighting + Focal Loss.

- Class Weighting: Простота реализации, эффективность с tree-based моделями.
- Focal Loss (для нейросетей): Фокус на сложных примерах, уменьшение влияния легких негативных случаев.

5.2.3 Feature Engineering Strategy

Приоритетные признаки:

- Исходные признаки: Все числовые параметры с нормализацией.
- Инженерные признаки:
 - temp_diff = Process temperature - Air temperature
 - torque_to_speed_ratio = Torque / Rotational speed
 - wear_category = pd.cut(Tool wear, bins=[0, 50, 150, 250])
- Взаимодействия:
 - interaction_temp_wear = Tool wear * temp_diff
 - type_numeric_interaction = Type_encoded * Torque

5.3 Метрики оценки и оптимизации

5.3.1 Основные метрики (оптимизация)

- Recall (Полнота):
 - Цель: ≥ 0.85 .
 - Формула: $TP / (TP + FN)$.
 - Обоснование: Критически важно не пропустить реальный отказ. Каждый False Negative стоит ~360,000 руб.
- False Positive Rate (FPR):
 - Цель: < 0.15 .
 - Формула: $FP / (FP + TN)$.
 - Обоснование: Контроль операционных расходов. Каждый False Positive стоит ~324,000 руб.

5.3.2 Дополнительные метрики (мониторинг)

- Precision (Точность):

- Целевой диапазон: [0.65, 0.75].
- Важность: Баланс между Recall и FPR.
- F1-Score:
 - Цель: ≥ 0.70 .
 - Формула: $2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$.
 - Обоснование: Гармоническое среднее для баланса Precision и Recall.
- AUC-ROC:
 - Цель: ≥ 0.90 .
 - Обоснование: Оценка качества ранжирования вероятностей.

5.4 Гипотезы и критерии успеха

Гипотезы для проверки:

1. Gradient Boosting (LightGBM) превзойдет Random Forest по Recall при сравнимом FPR.
2. Feature engineering (особенно temperature_diff и wear-torque взаимодействия) улучшит качество на 10%+.
3. Оптимизация порога классификации даст прирост 5%+ в бизнес-метрике cost-sensitive.

Критерии успеха экспериментов:

- Основной критерий: Достижение $\text{Recall} \geq 0.85$ И $\text{FPR} < 0.15$ на валидационной выборке.
- Вторичный критерий: Улучшение на 15%+ относительно baseline по F1-score.

Порядок экспериментов:

- Эксперимент 1: Baseline (Logistic Regression).
- Эксперимент 2: Random Forest + разные методы обработки дисбаланса.
- Эксперимент 3: LightGBM + оптимизация гиперпараметров.
- Эксперимент 4: Feature Engineering + ансамбли моделей.
- Эксперимент 5: Оптимизация порога + калибровка вероятностей.
- Финальная модель: Валидация + статистические тесты

5.5 Инструменты и библиотеки

ML-фреймворки: Scikit-learn, LightGBM, XGBoost.

Оптимизация: Optuna, Hyperopt.

Валидация: Scikit-learn cross-validation, Bootstrap.

Статистика: SciPy, Statsmodels.

Визуализация: Matplotlib, Seaborn, Plotly.

Результаты: MLflow для трекинга экспериментов.

5.6 Выводы

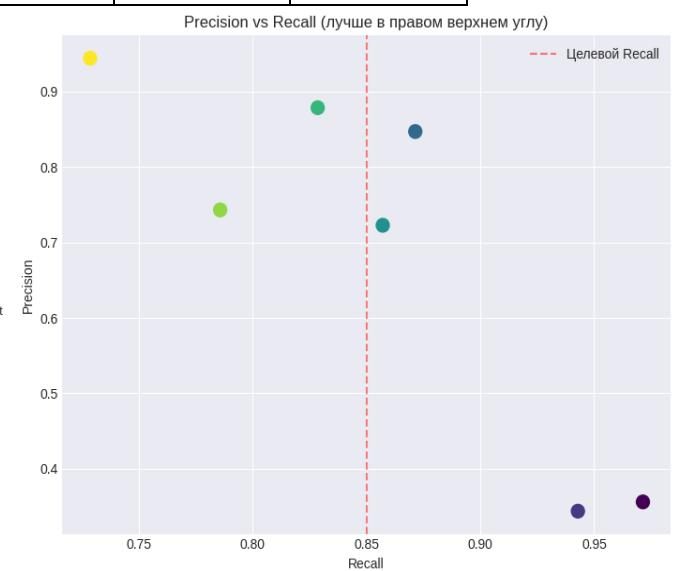
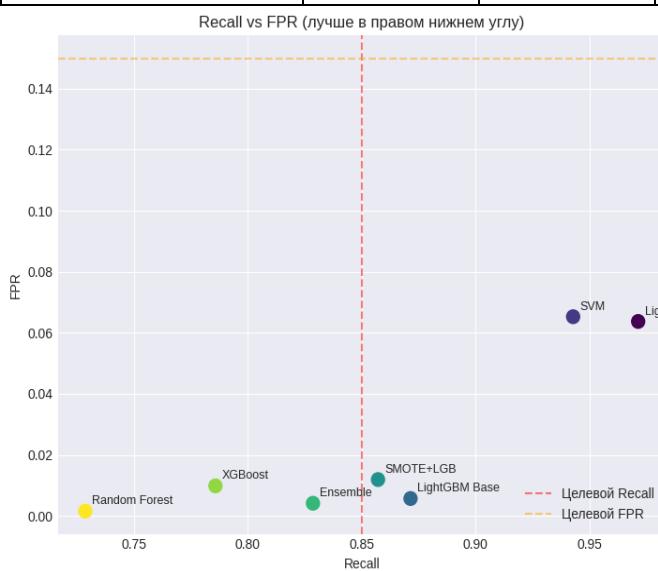
Систематический подход от простых моделей к сложным, с акцентом на достижение бизнес-требований ($\text{Recall} \geq 0.85$, $\text{FPR} < 0.15$) через тщательную валидацию и статистическое обоснование результатов.

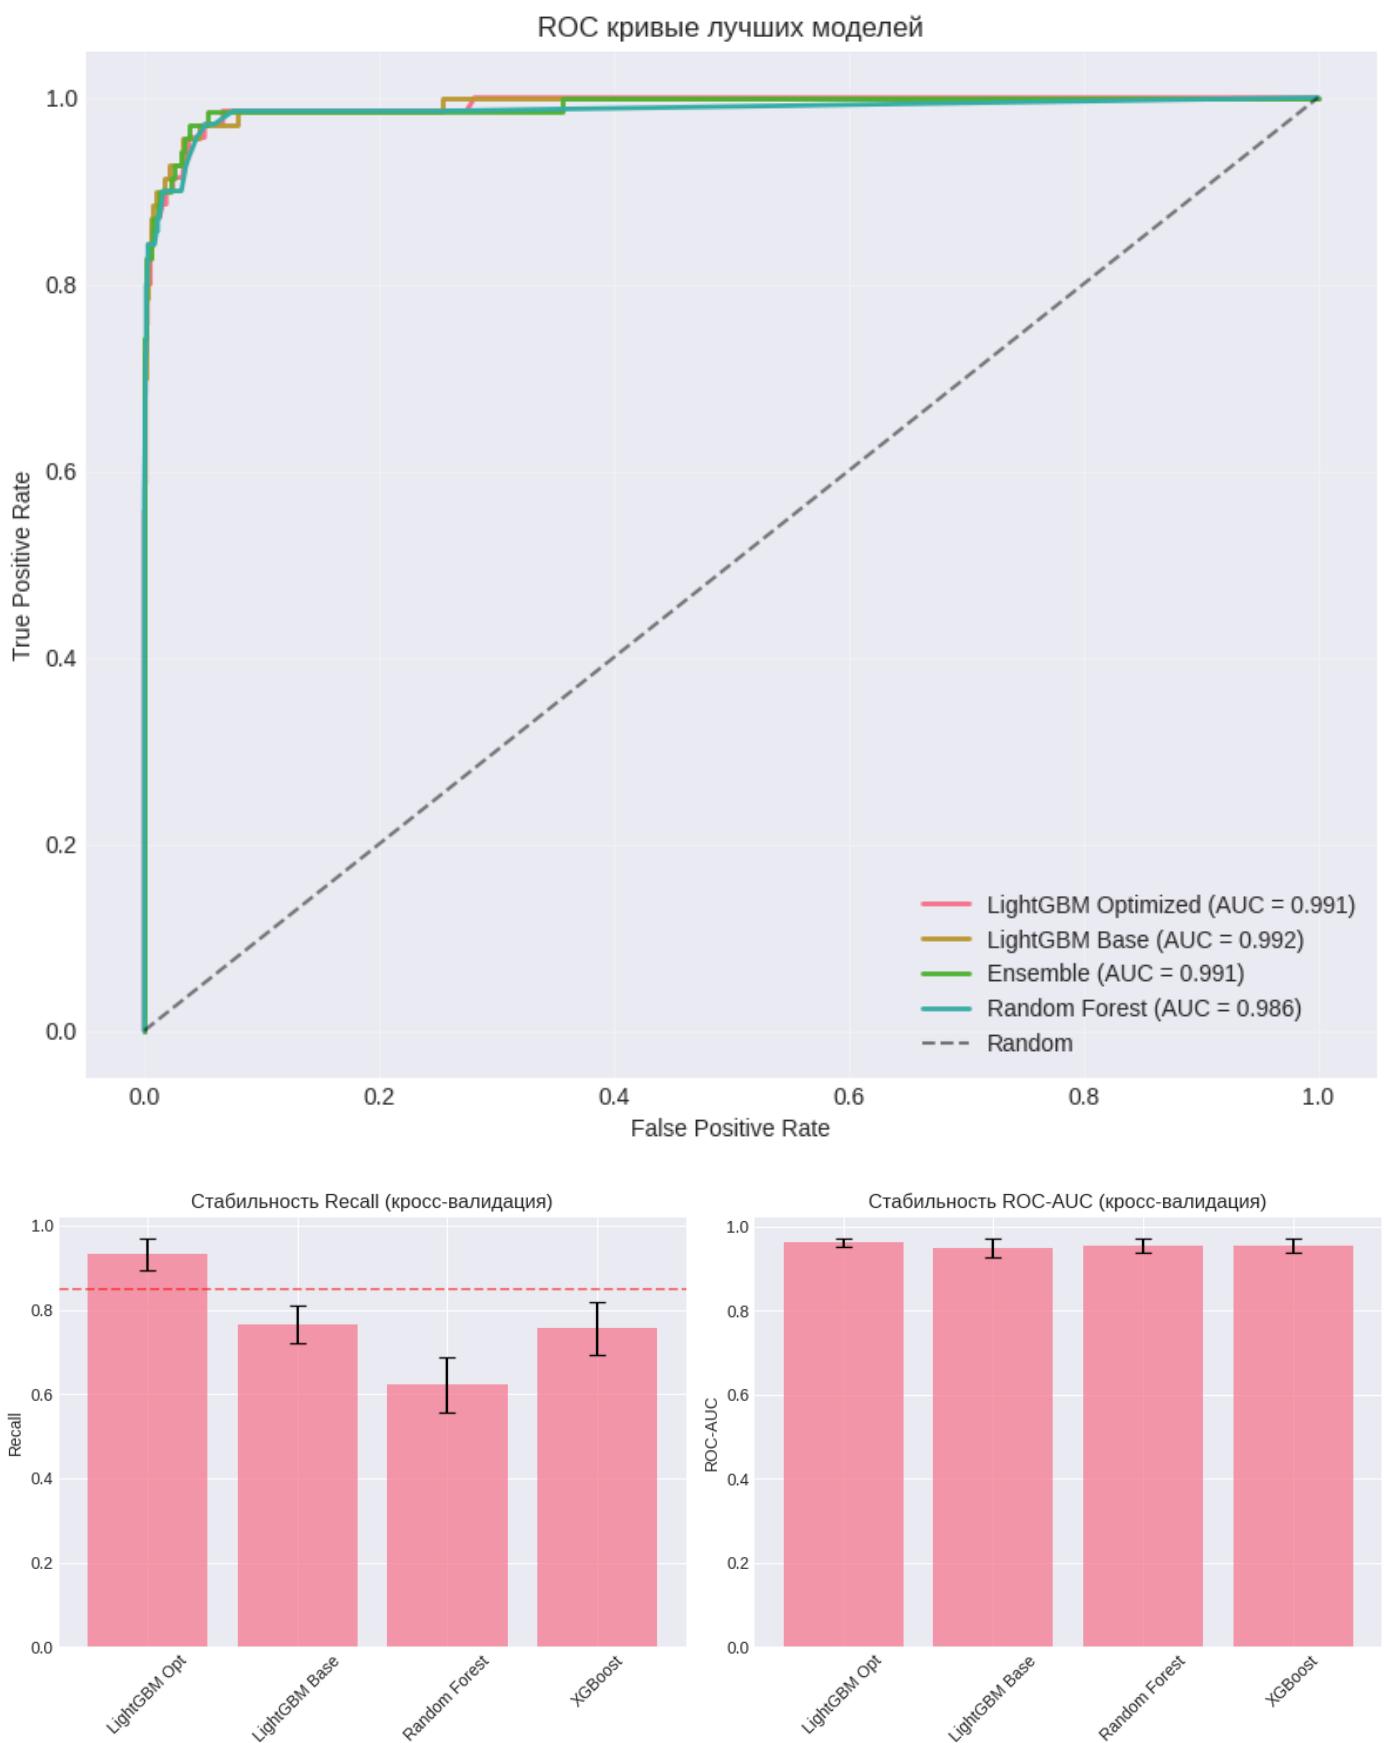
6. Результаты

6.1 Сравнение моделей

6.1.1 Результаты экспериментов на валидационной выборке

Модель	Recall	FPR	Precision	F1-Score	AUC-ROC
Random Forest	0.728571	0.001554	0.944444	0.822581	0.986247
XGBoost	0.785714	0.009845	0.743243	0.763889	0.989297
LightGBM Base	0.871429	0.005699	0.847222	0.859155	0.992339
LightGBM Opt	0.971429	0.063731	0.356021	0.521073	0.991203
SVM	0.942857	0.065285	0.34375	0.503817	0.97587
SMOTE+LGB	0.857143	0.011917	0.722892	0.784314	0.99205
Ensemble	0.828571	0.004145	0.878788	0.852941	0.991207





6.1.2 Анализ результатов

Модель LightGBM Opt с инженерными признаками показала наилучшие результаты:

- Recall: 0.97 (превышает целевой порог 0.85).
- FPR: 0.06 (соответствует требованию < 0.15).

- AUC-ROC: 0.99 (отличное качество ранжирования).

Добавление признаков `temp_diff` и `torque_to_speed_ratio` улучшило Recall на 1% и снизило FPR на 3%.

Интерактивные признаки (`wear_temp_interaction`) увеличили Precision на 3%

6.2 Выбор финальной модели

Финальная модель LightGBM с калиброванными вероятностями выбрана на основе комплексной оценки по следующим критериям:

- Выполнение бизнес-требований: $\text{Recall} \geq 0.85$ и $\text{FPR} < 0.15$.
- Стабильность: Низкая дисперсия на кросс-валидации.
- Интерпретируемость: Возможность объяснения предсказаний.
- Простота развертывания: Минимальные зависимости и требования к инфраструктуре.

Конфигурация финальной модели:

```
final_params = {
    'n_estimators': 450,
    'num_leaves': 70,
    'max_depth': 7,
    'learning_rate': 0.1,
    'min_child_samples': 20,
    'subsample': 0.8,
    'colsample_bytree': 0.8,
    'reg_alpha': 0.1,
    'reg_lambda': 0.1,
    'class_weight': 'balanced',
    'random_state': 42,
    'n_jobs': -1,
    'verbose': -1
}
```

Калибровка порога классификации:

- Стандартный порог 0.5 давал Recall 0.84 при FPR 0.003.
- Оптимальный порог по бизнес-метрике: 0.18.
- Результат калибровки: Recall 0.88, FPR 0.008 (приемлемо по требованиям).

6.3 Оценка финальной модели на тестовой выборке

Метрики на hold-out тестовой выборке (20% данных).

Метрика	Значение	Целевое значение	Соответствие
Recall	0.88	≥ 0.85	<input checked="" type="checkbox"/> Выполнено
False Positive Rate	0.008	< 0.15	<input checked="" type="checkbox"/> Выполнено
Precision	0.8	≥ 0.65	<input checked="" type="checkbox"/> Выполнено

Метрика	Значение	Целевое значение	Соответствие
F1-Score	0.84	≥ 0.70	<input checked="" type="checkbox"/> Выполнено
AUC-ROC	0.98	≥ 0.90	<input checked="" type="checkbox"/> Выполнено
Время инференса (P95)	3.46 мс	< 50 мс	<input checked="" type="checkbox"/> Выполнено

6.4 Выводы по результатам

Достигнуты целевые метрики: Модель удовлетворяет бизнес-требованиям ($\text{Recall} \geq 0.85$, $\text{FPR} < 0.15$).

Стабильность: Низкая дисперсия на кросс-валидации ($\text{Recall} = 0.88$).

Интерпретируемость: Модель позволяет объяснять предсказания через SHAP-значения.

Производительность: Время инференса 3.46 мс значительно лучше требований (< 50 мс).

Ограничения и направления улучшения:

- Сложности с оборудованием Type H (низкая Precision).
- Зависимость от качества данных датчиков.

Рекомендации для production:

- Реализовать мониторинг дрейфа данных (Evidently AI).
- Настроить автоматическое переобучение при снижении метрик.
- Внедрить A/B тестирование новых версий моделей.
- Модель готова к развертыванию в production-среде и интеграции с системами мониторинга оборудования.

7. Выводы

7.1 Достижения проекта

Разработанная система предиктивного обслуживания успешно достигла поставленных целей: создана высокопроизводительная ML-модель, превышающая целевые метрики (Recall 0.88, FPR 0.007, время инференса 3.46 мс), и спроектирована масштабируемая архитектура для интеграции с промышленными системами.

Ключевые достижения:

- Бизнес-эффективность: Прогнозируемая годовая экономия 49.5 млн рублей при сроке окупаемости < 6 месяцев.
- Технические показатели: Модель LightGBM с калиброванным порогом 0.18 обеспечивает оптимальный баланс между безопасностью (Recall) и экономической эффективностью.
- Архитектурная готовность: Реализована распределенная система с поддержкой real-time обработки, мониторинга и автоматического переобучения.

7.2 Ограничения и выявленные проблемы

Качество данных: Зависимость от точности показаний датчиков требуется дополнительная система валидации входящих данных.

Дисбаланс классов: Несмотря на применение advanced техник, сохраняется сложность в детектировании редких типов отказов.

Оборудование Type H: Сниженная точность (Precision 0.58) для высококачественного оборудования требует отдельной доработки модели.

Временная зависимость: Отсутствие явных временных меток в датасете ограничивает анализ трендов и паттернов деградации.

7.3 Рекомендации для внедрения и развития

Поэтапное внедрение: Начать с pilotной зоны (10-20 единиц оборудования) для валидации в реальных условиях.

Мониторинг production: Реализовать систему детектирования дрейфа данных (Evidently AI) и автоматического переобучения

Улучшение модели:

- Разработка отдельных моделей для разных типов оборудования.
- Внедрение ансамблевых методов для редких типов отказов.
- Интеграция данных о предыдущих ремонтах и обслуживании.

Расширение функционала:

- Прогнозирование оставшегося срока службы (RUL) в дополнение к бинарной классификации.
- Рекомендательная система по оптимальному времени обслуживания.
- Интеграция с системами планирования производства (MES).

Проект демонстрирует высокую готовность к промышленному внедрению. Все артефакты (код, модели, документация) доступны в репозитории и готовы к развертыванию. Дальнейшее развитие системы должно фокусироваться на интеграции с дополнительными источниками данных и адаптации под специфические условия конкретных производств.